Введение в машинное обучение

Автор: Ряжских Дмитрий

Лектор: Виктор Кантор

Физтех, Март 2026

Содержание

- Введение в предметную область
  - Методы повышения эффективности бизнеса
  - Формализация понятий Data Science
  - Типы задач машинного обучения
- Линейные модели
  - Градиентный спуск
  - Регуляризация

Базовый минимум пройденных курсов

Прежде чем начать читать этот конспект, настоятельно рекомендуется пройти следующие курсы:

1. Гармонический анализ
2. Математическая статистика
3. Линейная алгебра
4. Алгоритмы и структуры данных
5. Введение в Python

Введение в предметную область

Методы повышения эффективности бизнеса

Общая постановка задачи

Классическая задача бизнеса - максимизация прибыли. Формально, прибыль Π можно представить как разность между доходами R и расходами C:

$$\Pi = R - C \to \max$$

Методы, представленные ниже, направлены на увеличение компоненты R (доходы) и уменьшение компоненты C (расходы/потери).

1. Увеличение доходной части ($R \uparrow$)

Опр. **Лидогенерация** - это процесс привлечения потенциальных клиентов (лидов), заинтересованных в продукте или услуге. Является первым этапом воронки продаж.

Опр. **Рекомендательные системы** - это подкласс методов фильтрации информации, предназначенный для предсказания "рейтинга" или "предпочтения", которое пользователь присвоит еще не купленному товару.

Опр. **Умное ценообразование (Dynamic pricing)** - это стратегия установления гибких цен на товары или услуги в зависимости от текущих рыночных условий, спроса, предложения и поведения клиента.

Пример взаимосвязи

1. **Лидогенерация** доставляет "сырой" трафик.
2. **Рекомендательная система** увеличивает конверсию этого трафика (вероятность покупки $P(purchase|user)$), предлагая релевантный товар.
3. **Умное ценообразование** максимизирует маржинальность каждой совершенной покупки, подбирая оптимальную цену p_{opt}.

2. Минимизация потерь (Убытки $\downarrow$)

Опр. **Рисковый скоринг (Credit Scoring)** - это статистическая модель, используемая для оценки вероятности дефолта (невозврата) заемщика.

Опр. **Антифрод (Fraud Detection)** - это комплекс мероприятий и алгоритмов, направленных на выявление и предотвращение мошеннических транзакций.

3. Оптимизация затрат ($C \downarrow$)

Опр. **Оптимизация расходов (Cost Optimization)** - это процесс минимизации затрат на бизнес-процессы без потери качества. Включает в себя:

1. Снижение переменных издержек.
2. Сокращение постоянных издержек.
3. Повышение эффективности использования ресурсов.

Опр. **Автоматизация/Роботизация процессов (RPA)** - замена ручного труда сотрудников программными роботами для выполнения рутинных, повторяющихся задач с фиксированными правилами.

Итоговая структурная схема

Направление	Метод	Целевая функция (упрощенно)
Увеличение доходов	Лидогенерация	Увеличение мощности множества клиентов
	Рекомендательные системы	Увеличение $P(purchase)$
	Умное ценообразование	Увеличение p_{opt} (оптимальной цены)
Снижение потерь	Рисковый скоринг	Снижение $P(debt)$
	Антифрод	Снижение доли мошеннических транзакций
Оптимизация затрат	Оптимизация расходов	Снижение постоянных/переменных издержек
	Замена сотрудников роботами	Снижение операционных затрат на ручной труд

Формализация понятий Data Science

Связь понятий

Часто понятия **Artificial Intelligence (AI)** , **Machine Learning (ML)** и **Data Science (DS)** смешиваются. Их соотношение можно представить как вложенные множества.

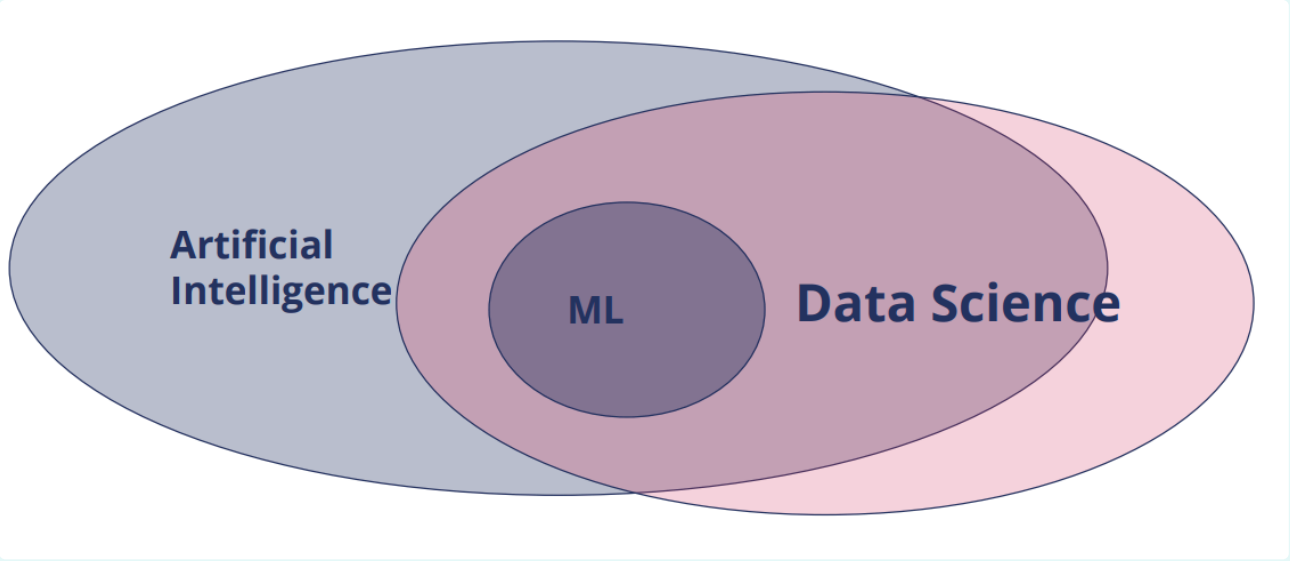

Опр. **Artificial Intelligence (AI)** - это общая область научных знаний, изучающая методы создания интеллектуальных агентов, способных воспринимать окружение и принимать действия, максимизирующие шансы на успех.

Опр. **Data Science (DS)** - это междисциплинарная область на стыке математики, статистики и программирования, целью которой является извлечение знаний и инсайтов из структурированных и неструктурированных данных.

Опр. **Machine Learning (ML)** - это подмножество методов AI, в котором способность к обучению не закладывается жесткими правилами, а выводится алгоритмически из данных. Модель f обучается на выборке $D = \{(x_i, y_i)\}_{i=1}^n$:

$$f^* = \arg\min_{f \in F} L(f(x), y)$$

где L - функция потерь, F - пространство гипотез. ML является инструментом DS.

разрыв страницы

Типы задач машинного обучения

Стандарт классификации

В машинном обучении все задачи классифицируются по двум основным признакам: типу выходной переменной (что прогнозируем) и наличию обучающей разметки (наличию целевых значений y).

1. Базовая классификация по характеру обучения

Опр. **Обучение с учителем** - парадигма машинного обучения, в которой модель обучается на размеченной выборке $D = \{(x_i, y_i)\}_{i=1}^n$. Для каждого объекта x_i (признаковое описание) известен правильный ответ y_i (целевая переменная). Задача - аппроксимировать функцию $f : X \to Y$.

Опр. **Обучение без учителя** - парадигма машинного обучения, в которой модель обучается на неразмеченной выборке $D = \{x_i\}_{i=1}^n$. Задача - обнаружить скрытые закономерности, структуру или зависимости в данных без использования "правильных ответов".

2. Задачи обучения с учителем

В рамках обучения с учителем выделяют два основных типа задач, которые определяются природой целевой переменной Y.

2.1. Классификация

Опр. **Классификация** - это задача отображения входного объекта $x \in X$ в дискретную целевую переменную $y \in \{C_i\}_{i=1}^k$, где C_i - метки классов.

Модель ищет решающую границу (разделяющую поверхность), которая отделяет объекты одного класса от другого в пространстве признаков.

Бизнес-примеры задач классификации

1. **Кредитный скоринг:** $y \in \{\text{вернет кредит}, \text{не вернет кредит}\}$.
2. **Сентимент-анализ (тональность текста):** $y \in \{\text{позитивный}, \text{негативный}, \text{нейтральный}\}$.
3. **Прогнозирование оттока:** $y \in \{\text{клиент уйдет}, \text{клиент останется}\}$.
4. **Тематическое моделирование (с учителем):** $y \in \{\text{спорт}, \text{политика}, \text{экономика}, \ldots\}$, где набор тем задан экспертом заранее.

2.2. Регрессия n)

Опр. **Регрессия** - это задача отображения входного объекта $x \in X$ в непрерывную целевую переменную $y \in \mathbb{R}$.

Цель - построить функцию, описывающую зависимость между переменными. Простейший вид - линейная регрессия:

$$y = \beta_0 + \beta_1 x_1 + \ldots + \beta_n x_n + \epsilon$$

где β - коэффициенты модели, ϵ - ошибка.

Бизнес-примеры задач регрессии

1. **Прогнозирование финансовых метрик:** размер выплаты по задолженности, цена ценной бумаги.
2. **Производственные задачи:** прогнозирование массы дефекта на производстве.
3. **Физические величины:** прогнозирование температуры воздуха, давления, скорости ветра.

3. Задачи обучения без учителя

В рамках обучения без учителя центральное место занимает задача кластеризации.

3.1. Кластеризация

Опр. **Кластеризация** - это задача разбиения множества объектов $X = \{x_1, x_2, \ldots, x_n\}$ на группы (кластеры) таким образом, чтобы объекты внутри одной группы были максимально похожи друг на друга (высокая внутрикластерная гомогенность), а объекты из разных групп - максимально различны (высокая межкластерная гетерогенность).

$$\text{Найти разбиение: } X = \bigcup_{j=1}^{k} C_j, \quad C_i \cap C_{j \neq i} = \emptyset$$

Количество кластеров k может быть задано априори или определено алгоритмом в процессе работы.

Линейные модели

Введение основных понятий

- Пусть X - пространство всевозможных признаков исследуемого объекта. Для удобства исследования признаки преобразуют к числовым параметрам, поэтому боо можно говорить, что $X \subset \mathbb{R}^d$.
- $x \in X$ - вектор признаков для конкретного объекта. Далее часто мы будем считать, что $x \subset X$ - выборка из нескольких векторов признаков, то есть $x \in Mat_{\ell \times d}(\mathbb{R})$ (мы это делаем чтобы одновременно обрабатывать все вектора признаков, применяя лишь одну операцию к выборке).
- y - целевой параметр, который мы хотим предсказать по вектору признаков.
- Y - множество значений целевого параметра (обычно числа).

Опр. Линейная модель имеет вид **дискриминантной функции**:

$$f(x) = w_0 + \sum_{i=1}^{d} w_i x_i = w_0 + \langle w, x \rangle$$

- $w = (w_1, \ldots, w_d)^T \in \mathbb{R}^d$ - веса линейной модели
- $w_0 \in \mathbb{R}$ - **порог** (свободный, корректирующий, член линейной модели)
- Для упрощения записи часто вводят фиктивный признак $x_0 = 1$, тогда:

$$f(x) = \langle w, x \rangle = w^T x$$

  где w и x - это уже расширенные векторы, включающие w_0 и x_0.

Опр. **Обучение линейной модели** - поиск вектора весов w, минимизирующего сумму потерь на обучающей выборке.

Линейная классификация

Опр. **Линейный классификатор** - это алгоритм $a(x)$, значение которого определяется знаком функции линейной модели:

$$a(x) = \text{sign}(f(x)) = \begin{cases} +1, & \text{если } f(x) > 0 \\ -1, & \text{если } f(x) \leq 0 \end{cases}$$

- То есть в линейной классификации $Y = \{\pm 1\} \cong B$

Геометрическая интерпретация

Уравнение $\langle w, x \rangle + w_0 = 0$ задает **разделяющую гиперплоскость** в d-мерном пространстве признаков. Вектор весов w является нормалью (перпендикуляром) к этой гиперплоскости. Скалярное произведение $\langle w, x \rangle$ пропорционально расстоянию от точки x до плоскости со знаком. Свободный член w_0 определяет смещение плоскости относительно начала координат.

Отступ (Margin)

Опр. **Отступом** объекта x_i называется величина $M_i = y_i \cdot f(x_i)$, где $y_i \in \{-1, +1\}$ - истинная метка класса.

Свойства отступа:

1. $M_i > 0$ - объект классифицирован **верно** (знак f совпадает с y_i).
2. $M_i \leq 0$ - объект классифицирован **неверно** (знак f не совпадает с y_i).
3. Чем больше $|M_i|$, тем "увереннее" классификатор и тем дальше объект находится от разделяющей гиперплоскости.

Функция потерь (Loss Function)

Исходная задача минимизации числа ошибок классификации является трудно минимизируемой (кусочно-постоянная функция). Поэтому переходят к минимизации верхней оценки.

Опр. **Эмпирический риск** - функционал качества, который требуется минимизировать:

$$Q(w) = \sum_{i=1}^{\ell} \mathbb{1}_{\{M_i(w)<0\}}$$

Так как эта функция негладкая, ее заменяют на суррогатную **функцию потерь** $\mathcal{L}(M)$:

$$\tilde{Q}(w) = \sum_{i=1}^{\ell} \mathcal{L}(M_i(w)) \to \min_w$$

Ниже представлены различные функции потерь и их свойства.

Функция потерь	Формула	Выпуклость	Гладкость	Производная	Чувствительность к выбросам
Индикаторная	$\mathbb{1}_{\{M\le 0\}}$	-	Нет	$\nexists$	Высокая
Персептронная	$\max(0, -M)$	+	Частично	$-\mathbb{1}_{\{M<0\}}$	Высокая
Шарнирная (SVM)	$\max(0, 1-M)$	+	Частично	$-\mathbb{1}_{\{M<0\}}$	Средняя
Логарифмическая	$\log(1+e^{-M})$	+	Да	$-\frac{1}{1+e^M}$	Средняя
Экспоненциальная	e^{-M}	+	Да	$-e^{-M}$	Очень высокая
MSE (L2)	r^2	+	Да	$2r$	Очень высокая
MAE (L1)	$\|r\|$	+	Частично	$\mathrm{sign}(r)$	Низкая
Huber	кусочно-квадратичная	+	Частично	$\cdots$	Средняя
Квантильная	кусочно-линейная	-	Частично	$\cdots$	Низкая

Линейная регрессия

Линейная регрессия решает задачу восстановления непрерывной зависимости. То есть $Y \subseteq \mathbb{R}$.

Опр. **Линейная регрессия** - модель вида:

$$a(x) = \langle w, x\rangle + w_0 \quad (\text{или можно записать просто } \langle w, x\rangle)$$

Аналитическое решение (для квадратичной функции потерь)

Если добавить фиктивный признак $x_0 = 1$ и использовать квадратичную функцию потерь, можно получить решение в замкнутой форме. Пусть F - матрица "объекты-признаки" размера $\ell \times (d+1)$, y - вектор целевых значений, тогда:

$$Q(w) = (Fw - y)^T(Fw - y)$$

Найдём стационарные точки:

$$\nabla Q(w) = \frac{\partial Q}{\partial w}(w) = 2F^T(Fw - y) = 0 \iff w = (F^TF)^{-1}F^Ty$$

Проверим что это точка глобального минимума:

$$\frac{\partial}{\partial w}\nabla Q(w) = 2F^TF \ge 0 \ - \ \text{в силу свойств квадратичной формы ЕП}$$

Значит $w = (F^TF)^{-1}F^Ty$ - действительно оптимальные веса при квадратичной функции потерь.

+ы & -ы линейных моделей

✓ **Преимущества**

- Простота реализации и применения.
- Высокая скорость обучения и работы.
- Хорошо работают при большом количестве признаков.
- Устойчивы при малом количестве данных (благодаря регуляризации).
- Интерпретируемость (веса показывают важность признаков).

× **Недостатки**

- Предполагают линейную зависимость, что может быть слишком грубым допущением.
- Чувствительны к масштабу признаков (требуют нормализации/стандартизации).

Градиентный спуск (Gradient Descent)

Алгоритм градиентного спуска работает итеративно. Пусть w_k - веса, полученные на k-й итерации алгоритма. Пусть $\eta : \mathbb{N}_0 \to \mathbb{R}$ - функция, определяющая темп обучения, а $\eta(k) = \eta_k$, тогда правило обновления весов* в полном градиентном спуске будет иметь вид:

$$w_{k+1} = w_k - \eta_k \nabla \tilde{Q}(w_k)$$

Отрицательный градиент в точке указывает на направление наиболее сильного уменьшения функции, то есть со временем веса сойдутся в точку локального минимума. Градиент функционала для линейной модели выглядит так:

$$\nabla \tilde{Q}(w) = \frac{1}{\ell} \sum_{i=1}^{\ell} y_i x_i \mathcal{L}'(M_i)$$

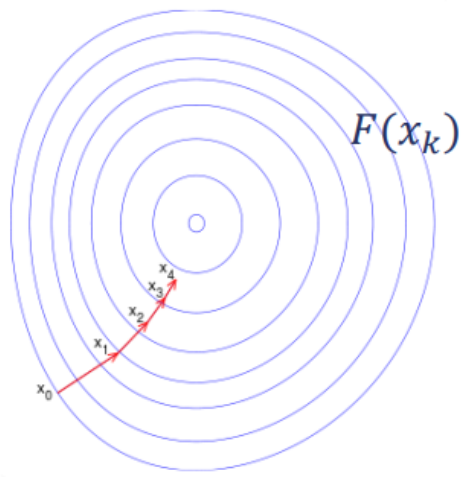

Стохастический градиентный спуск (SGD)

При большом объёме выборки ($\ell >> 1$) возникает проблема с тем, что алгоритм слишком долго работает. Для ускорения обучения на больших данных используется стохастическая аппроксимация. Пусть x_k - случайный вектор из x, выбранный на k-й итерации, а y_k - соответствующее ему целевое значение, тогда

$$w_{k+1} = w_k - \eta_k \nabla \mathcal{L}(w_k)$$

В линейной модели:

$$\nabla \mathcal{L}(w_k) = y_k x_k \mathcal{L}'(M_k)$$

Теорема о статистической эквивалентности GD и SGD

Градиент, вычисленный методом SGD, является несмещённой оценкой истинного градиента GD:

$$\mathbb{E}_i[\nabla \mathcal{L}_i(w)] = \nabla \tilde{Q}(w)$$

Доказательство

Рассмотрим математическое ожидание стохастического градиента по равномерно распределенному индексу i:

$$\mathbb{E}_i(\nabla \mathscr{L}_i(w)) = \sum_{i=1}^{\ell} P(i) \cdot \nabla \mathscr{L}_i(w)$$

При равномерном распределении $P(i) = \frac{1}{\ell}$, следовательно:

$$\mathbb{E}_i(\nabla \mathscr{L}_i(w)) = \frac{1}{\ell} \sum_{i=1}^{\ell} \nabla \mathscr{L}_i(w) = \nabla Q(w)$$

Следствие

Правило обновления SGD можно представить как:

$$w_{k+1} = w_k - \eta_k \nabla Q(w_k) + \eta_k \underbrace{(\nabla Q(w_k) - \nabla \mathscr{L}_{i_k}(w_k))}_{\varepsilon_k}$$

где ε_k - шум с нулевым математическим ожиданием: $\mathbb{E}\varepsilon_k = 0$.

Теорема о скорости сходимости GD

Обозначим w^* - оптимальный вектор весов. Пусть:

1. Q - μ-сильно выпуклая функция *(то есть* $\forall w, w' \ : Q(w') \geq Q(w) + \nabla Q(w)^T(w' - w) + \frac{\mu}{2}\|w' - w\|^2$*)*
2. ∇Q - липшицева с константой Липшица L
3. $\forall k \ : \ \eta_k \leq L^{-1}$
   Тогда алгоритм GD обеспечивает линейную скорость сходимости:

$$Q(w_k) - Q(w^*) \leq \left(1 - \frac{\mu}{L}\right)^k (Q(w_0) - Q(w^*))$$

Теорема о скорости сходимости SGD

Обозначим w^* - оптимальный вектор весов. Пусть:

1. Q - μ-сильно выпуклая функция *(то есть* $\forall w, w' \ : Q(w') \geq Q(w) + \nabla Q(w)^T(w' - w) + \frac{\mu}{2}\|w' - w\|^2$*)*
2. $\exists \sigma > 0 \ : \ \mathbb{D}(\|\nabla Q\|) < \sigma^2$ - ограниченная дисперсия нормы градиента
3. $\forall k \ : \ \eta_k \leq (\mu k)^{-1}$
   Тогда алгоритм GD обеспечивает сублинейную скорость сходимости:

$$\mathbb{E}(Q(w_k) - Q(w^*)) \leq O\left(\frac{\sigma^2}{\mu k}\right), \quad k \to \infty$$

Сравнительный анализ GD и SGD

Характеристика	GD	SGD
Асимптотика итерации	$\Theta(\ell d)$	$\Theta(d)$
Память итерации	$\Theta(\ell d)$	$\Theta(d)$
Скорость сходимости	$O(e^{-k})$	$O(k^{-1})$
Зависимость от точности ε	$O\left(\log \frac{1}{\varepsilon}\right)$ итераций	$O\left(\frac{1}{\varepsilon}\right)$ итераций
Траектория	Детерминированная, гладкая	Стохастическая, шумная

Характеристика	GD	SGD
Работа с выбросами	Устойчив	Может раскачиваться

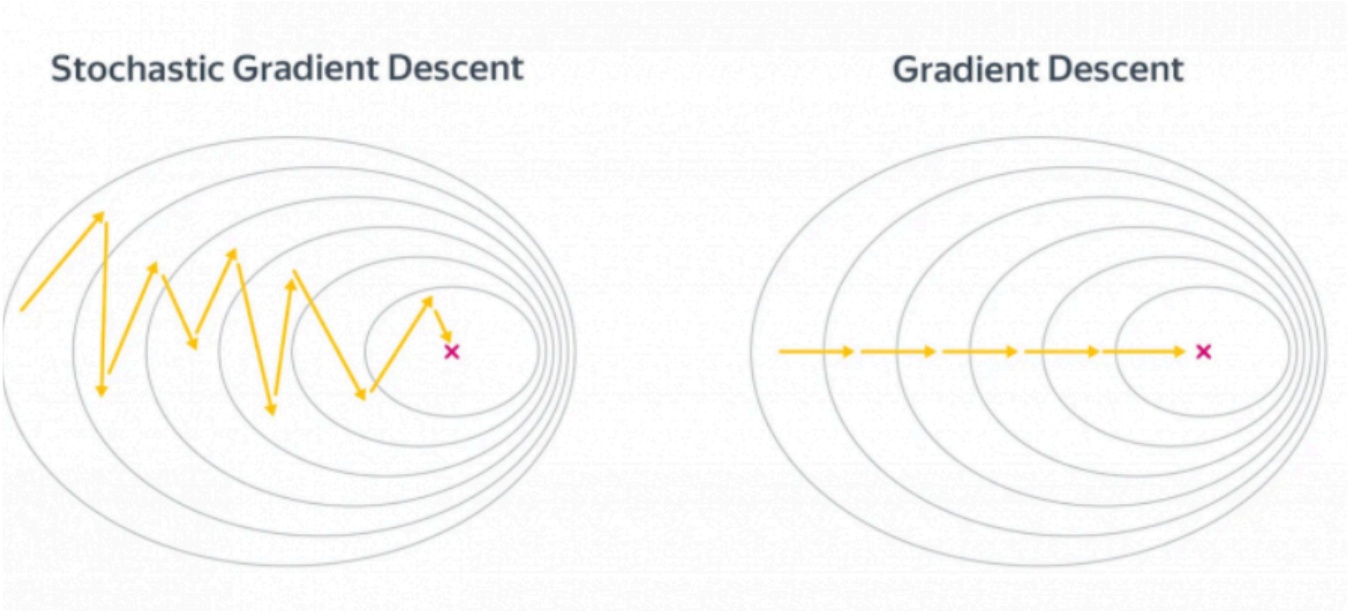

Регуляризация

Переобучение

Смысл любой модели по конечному числу данных решений получить общее решение. Явление **переобучения** (overfitting) проявляется в том, что модель слишком сильно подстраивается под обучающие данные и теряет обобщающую способность, что несёт отрицательный характер при анализе данных. В линейных моделях это часто выражается в слишком больших значениях весов w_n.

Опр. **Регуляризация** - метод добавления дополнительного ограничения на вектор весов w для борьбы с переобучением.

Исходная задача оптимизации заменяется на штрафную:

$$\tilde{Q}_{\text{reg}}(w) = \sum_{i=1}^{\ell} \mathcal{L}(M_i) + \gamma V(w) \to \min_w$$

где $V(w)$ - **регуляризатор** *(штраф за сложность модели)*, а $\gamma > 0$ - **коэффициент регуляризации**.

Типы регуляризаторов

1. **L2-регуляризация (Ridge, гребневая регрессия):**

$$V(w) = \|w\|_2^2 = \sum_{n=1}^{d} w_n^2$$

   - Приводит к тому, что веса становятся равномерно малыми.

2. **L1-регуляризация (LASSO (Least Absolute Shrinkage and Selection Operator)):**

$$V(w) = \|w\|_1 = \sum_{n=1}^{d} |w_n|$$

   - Приводит к *разреженности* вектора весов: многие веса становятся равными нулю.
   - Выполняет *отбор признаков*.

Сравнение L1 и L2

Заметим, что названия L1 и L2 взяты не просто так. По факту данные регуляризаторы являются нормами в пространствах $\mathcal{L}^1$ и $\mathcal{L}^2$ интегрируемых по Лебегу функций. L1-регуляризация делает вектор весов разреженным, обнуляя неинформативные признаки. L2-регуляризация делает веса маленькими, но не обнуляет их.

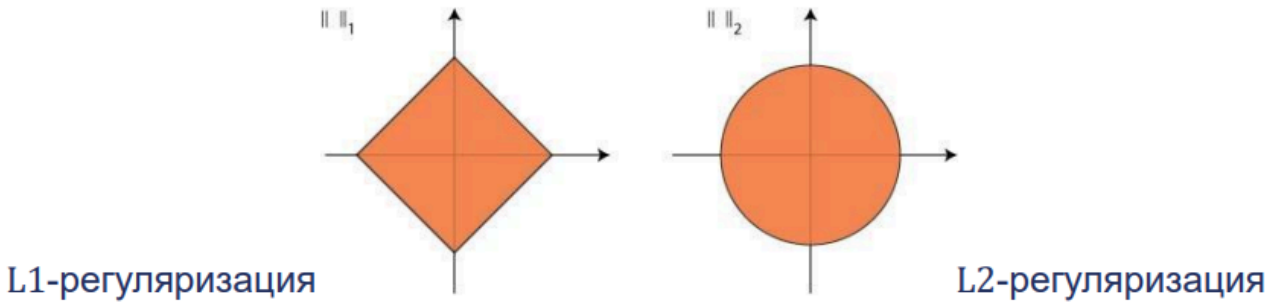

Виды линейной регрессии с регуляризаторами

1. **Обычная линейная регрессия (МНК):**

$$L(y, a) = (y - a)^2, \quad \gamma = 0$$

2. **Гребневая регрессия (Ridge regression):**

$$L(y, a) = (y - a)^2, \quad V(w) = \|w\|_2^2$$

3. **LASSO-регрессия:**

$$L(y, a) = (y - a)^2, \quad V(w) = \|w\|_1$$

разрыв страницы

Примечания

1. Оригинальный конспект в последней редакции можно найти на моём GitHub: https://github.com/Leg15Coder/Digital-garden
2. По всем найденным ошибкам и опечаткам можно писать в GH issues: https://github.com/Leg15Coder/Digital-garden/issues или мне в ЛС https://t.me/dimka_ryaz